UNIVERSITÄT
LUZERN

KULTUR- UND SOZIALWISSENSCHAFTLICHE FAKULTÄT

DEPT. OF SOCIOLOGY

BIG DATA & MACHINE LEARNING IN INNOVATION RESEARCH

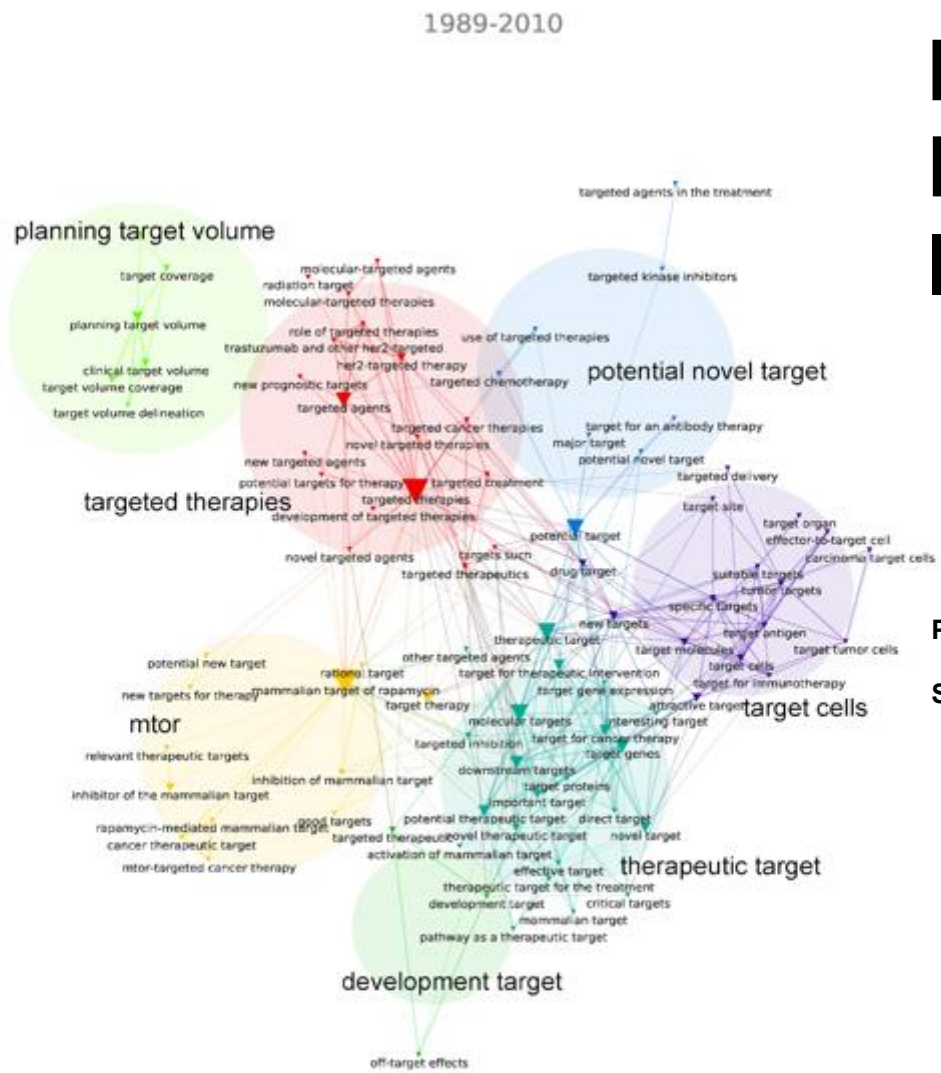

PROF. DR. SOPHIE MÜTZEL

SOPHIE.MUETZEL@UNILU.CH

,

INNOVATION RESEARCH

Innovation is not spontaneous invention.

Rather,
it is the **recombination** of existing elements transformed into "**newness**."
process and **non-linear,** includes failures, uncertainty and contested **interpretation**

Categorization processes
labels help to communicate new category, e.g., smart phone, SUV

OLD AND NEW LARGE-SCALE DATA

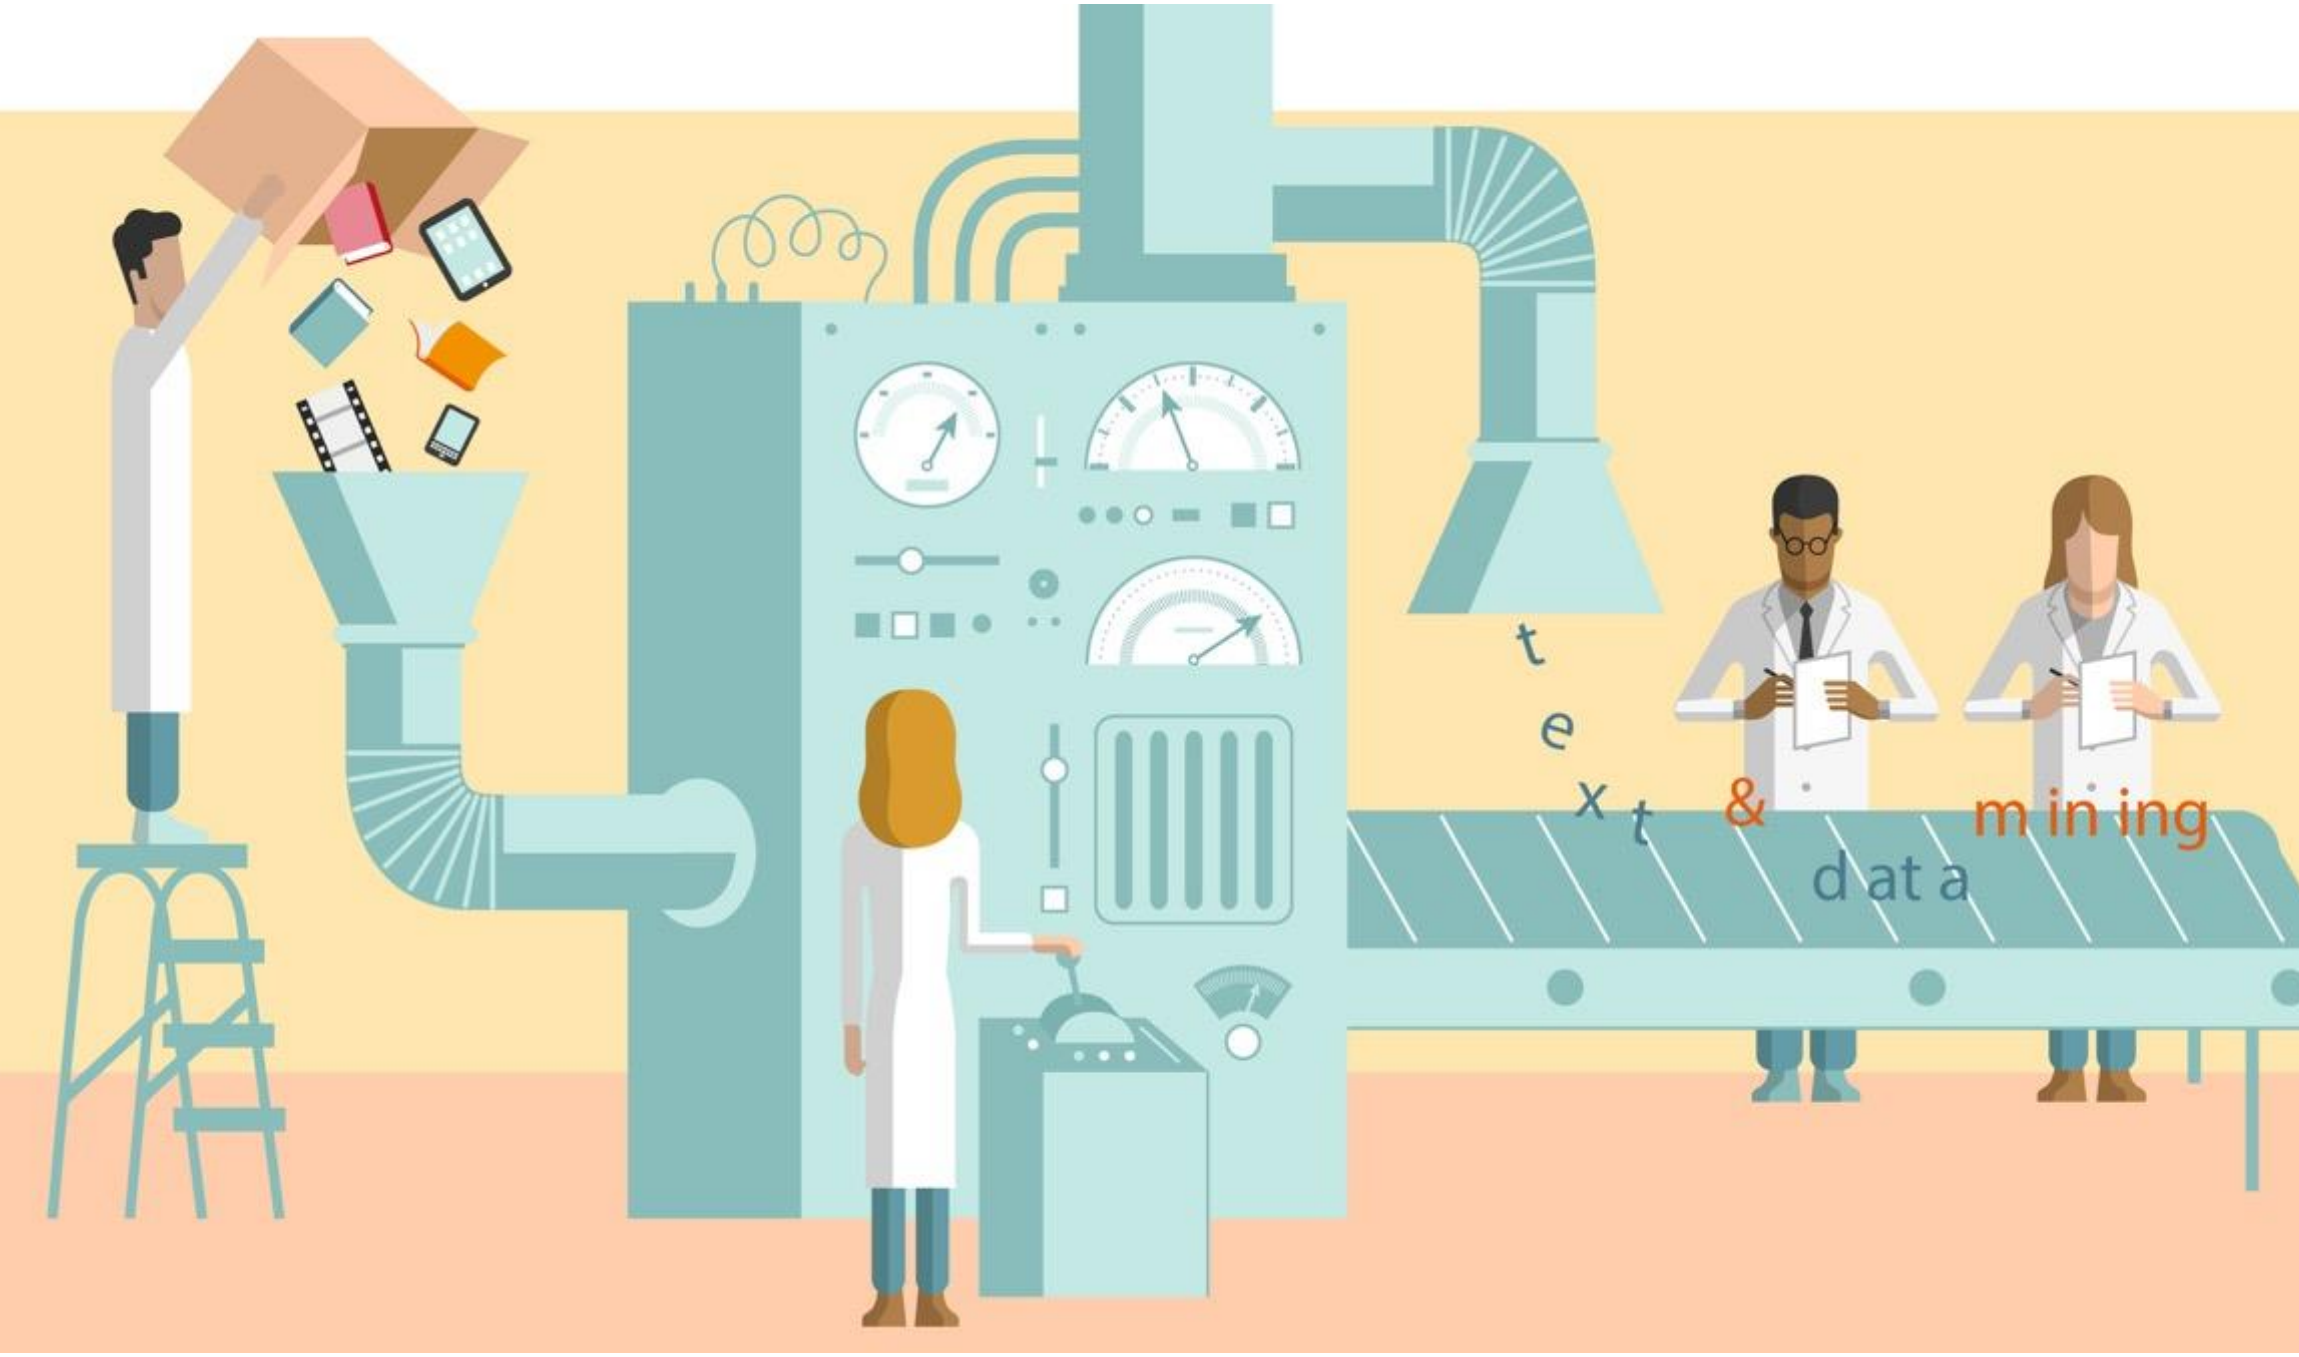
text & mining
data

MESSY DATA

AFTONBLADET

KVÄLLSUPPLAGA

Nr 67 Lördagen den 10 mars 1951

ssåtal för 220.000 cigar

ligt tjänsterum var

UGGELGÖMMA

lacken tog chansen

rätt upp i molnen

Fjällvidderna,

DATA CURATION

```
508;20030313;2003;Tip;3;klarzustellen piacenza hervorragend hauptgerichte tageskarte thunfisch aceto balsamico roulade gratiniert fenchel ausgesproc
509;20030321;2003;Zitty;3;kiez boxhagenerplatz aufgekratzte hibbelig phase ruhe triangolgo vorreiter italienisch angekommen wohltuend schlichter nob
510;20030411;2003;Tip;4;schlesischestrasse gegend gemuetlich zeitunglesen kaffeetrinken gewuenscht anfang jeansladen baeckerei betreten cream beduer
511;20030412;2003;Tip;4;labskaus gruenkohl pinkel kulinarisch norddeutsche unerschuetterlich liebhaber hamburg ruegen enttaeuscht fetttriefend versa
512;20030421;2003;Zitty;4;pastellgetuenchte sachlichkeit dominiert schankraum renovierten sozialistischen prachtbau werktaetig anfang karlmarxallee
513;20030511;2003;Tip;5;einhundert licht aufgegangen osramhoefen gluehbirne hergestellt komplex vergangenen jahrhunderts gewerbepark erstanden schut
514;20030521;2003;Zitty;5;hundert ueberteuertes trinken einfuehrung neuen waehrung verschwendet moeglichkeit anspruchsvoll kostengruenden angewieser
515;20030611;2003;Tip;6;wort pankow bekam zdf kommentatoren inbruenstig veraechtlich unterton beigefuegt residierte pankower majakowskiring leitende
516;20030612;2003;Tip;6;mela versorgungsinder schein truegt inneneinrichtung warmem orange gehalt angeblich farbe orange menschen vitalisierend freu
517;20030613;2003;Tip;6;hoppla glatt irrglauben befunden texmex welle cancun nummer mexikanern unterscheiden dunkle holzmoebel einheitskleidung flec
518;20030621;2003;Zitty;6;falsch verabredet nett italienisch lauschig freundlichekellner vielversprechend wartet aperitif umgehend herzallerliebste
519;20030711;2003;Tip;7;ernst reuter charlottenburg augen geoeffnet kreisverkehr hand moderner buerobauten umzingeln krieg zerstoerte knie artusia a
520;20030712;2003;Tip;7;passant bedeutet beilaeufig begriffe passant gerecht helle modisch gelbton gehaltene betreten atmosphaere ruhe entspanntheit
521;20030713;2003;Tip;7;neu restaurantchef ronald ottevanger neu kuechenchef wolfgangkanow plueschig albrechtshof ausgediente gediegene hotelrestaur
522;20030721;2003;Zitty;7;zeitgemaess betreiber beliebtesten wasserturmkiezes tuana schwierigsten ausgesucht mustafa arif leuchtender stern ueberset
523;20030811;2003;Tip;8;buerger volckspreisen olivervolck kreuzberg wende wiedervereinigte kindertage erinnerte fand boxhagenerplatz idee volckslade
524;20030812;2003;Tip;8;pankow jabs keen pankow jabs keen uffjefressen fremder jier bolle beruechtigtsten gassenhauer janz koestlich amuesiert wider
525;20030813;2003;Tip;8;freunden neue maengelquartett ausprobieren gedruckte baumaengel gegeneinander ausspielen kartenspiel miriam nadja themas eir
526;20030821;2003;Zitty;8;mittagspause laluz qualitaet ambiente stimmen freut angenehm restaurierten saal stahltresen gruengeschwaemmte saeulen flai
527;20030911;2003;Tip;9;nataliiiiie schmachtet gilbert becaud lebensbejahender kugelrunder grauer riesenmaehne mauveblau provenzalisch lavendels leu
528;20030912;2003;Tip;9;desi kocht pakistanisch zurueckhaltend dekoriert maurisch boegen schmiedeeisern umkraenzte vorstadtidylle unaufdringlich her
529;20030913;2003;Tip;9;haliflor schwedterstrasse reichhaltig fruehstueck gemischt vegetarisch schokolade schweinetasse verspricht getraenke prompt
530;20030921;2003;Zitty;9;einladend tempo box schnupfennase schnellimbiss leuchtet rot abschrecken vergnuegungsmeile simondachstrasse gedaempftes li
531;20031011;2003;Tip;10;kudamm gehaetschelter prachtboulevard weltniveau angeblich grossgasse leerstand fastfood stationen billiglaeden verkommen c
532;20031012;2003;Tip;10;abwaerts schreitend keller schrill blau gemusterten teppich suedsee gefuehle steigernd mai tai sichtend reservierung benach
533;20031021;2003;Zitty;10;winter schweinekalt norden marheinekeplatz norddeutsche erfahrene kollege freuten gruenkohl pinkel labskaus standen unwis
534;20031111;2003;Tip;11;fortysomethings existent pariserstrasse junges halb lautstarkes voelkchen zeiger teure hotelrestaurants verziehen angemesse
535;20031112;2003;Tip;11;empfehlung merian klebt glastuer indisch maerz vorgaenger gemeint aufgegeben vorbildlich eingedeckt rostrot sitzbezuege kom
536;20031113;2003;Tip;11;frueheren leben ganymed beschwert hervorragend franzoesisch aufgedreht brasserie bodenstaendig gassoulet liebsten geraeuche
537;20031121;2003;Zitty;11;indisch sinn ziviler schonend geldbeutel verwendung mengen kohlenhydrathaltig weissenfladen huelsenfruechten zahlreichen
538;20031211;2003;Tip;12;schwergewichtig politiker fand peinlich normale menschen angepassten lederstuhl rattangeflecht seitenstuetzen auszutauscher
539;20031212;2003;Tip;12;seeluft hungrig ergeht petrijuenger geduldig harren gestade scharfen lanke hungersnot geniessbar weissfische haken manne ge
```

PATTERNS FROM TEXTS

Figure 4 Structural Analysis for Category Formation, 1870–1915

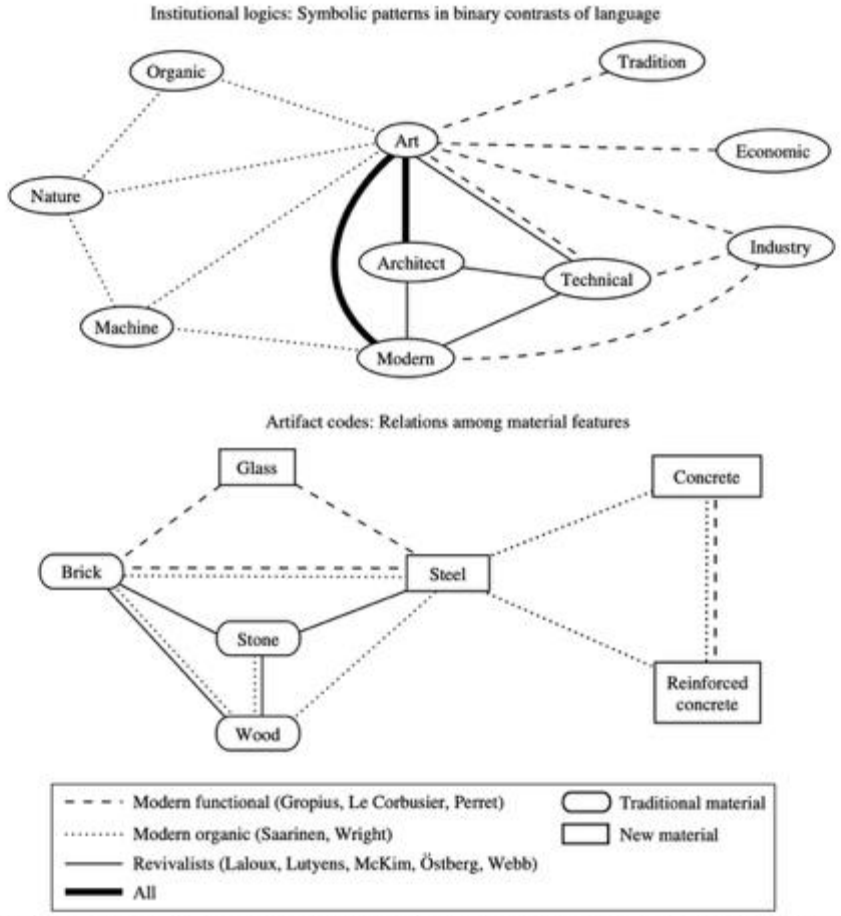

Notes. Nodes are placed to facilitate visualization. The distance between nodes is not indicative of any network measure of association. Samples are composed of 24 articles and 25 exemplar buildings.

Jones et al. 2016 on the formation of the de novo category “modern architecture”

- hand-coding of texts
- mapping the categories
- identify 3 periods of category formation

TOPIC MODELING (LDA)

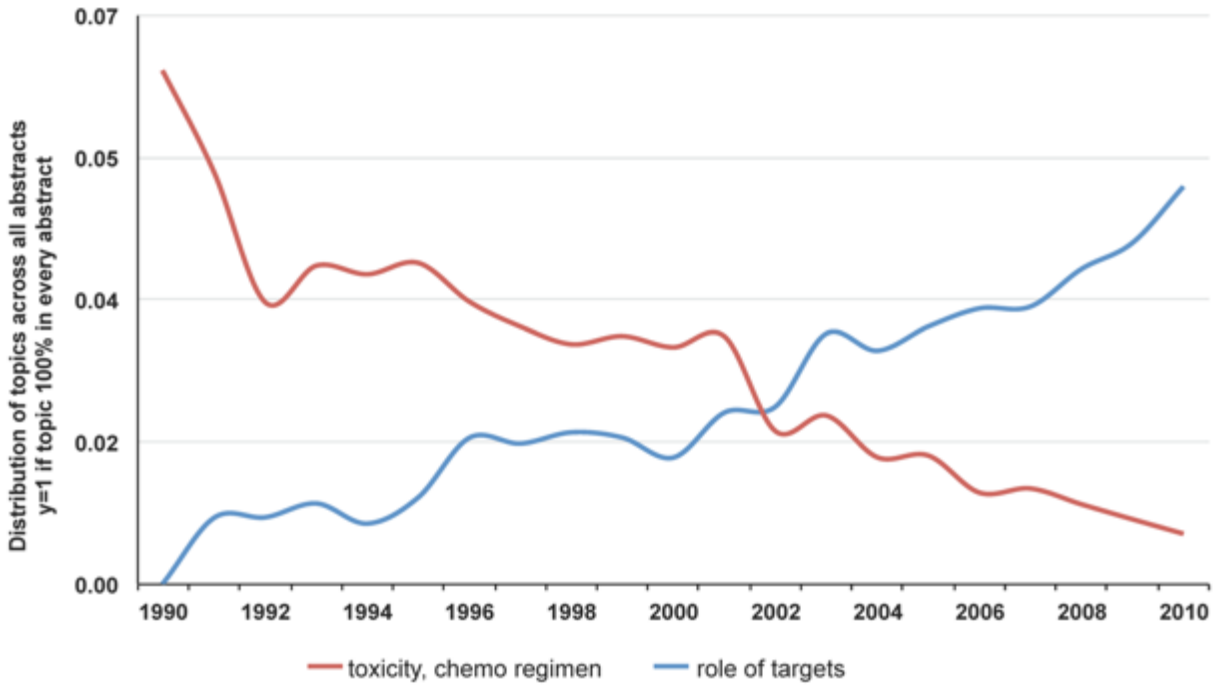

Distribution of topics "role of targets" and "toxicity, chemo regimen" across oncological discussions on breast cancer therapy.
Web of Science abstracts, 1990-2010, n=31,000, 200-topic Gibbs LDA.

Mützel 2022

- Search for latent themes in texts
- Unsupervised learning. Treats documents as a “bag of words” to find patterns of co-occurrence.
- Inductive exploration. Little a priori decisions necessary, no dictionaries.
- Interpretive Uncertainty. The algorithm finds patterns; the researcher must label and interpret them.

WORD EMBEDDINGS (WORD2VEC)

Figure 2. (Color online) Schematic Illustration of Low vs. High Team Discursive Diversity Scores

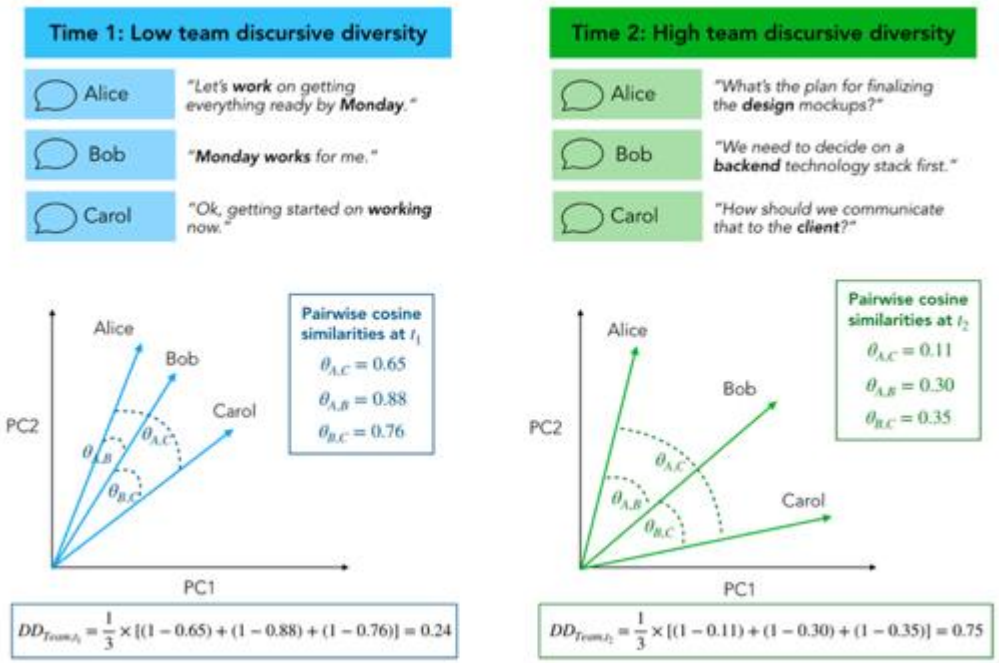

Lix et al. 2022 on discursive diversity and team performance

- "Geometry of meaning"
- Transforms words into numeric vectors. Words appearing in similar contexts are mapped closer together in space.
- Creates "Conceptual Spaces." Allows us to measure the distance between concepts.
- Static meanings of terms

CONTEXTUAL EMBEDDINGS (BERT)

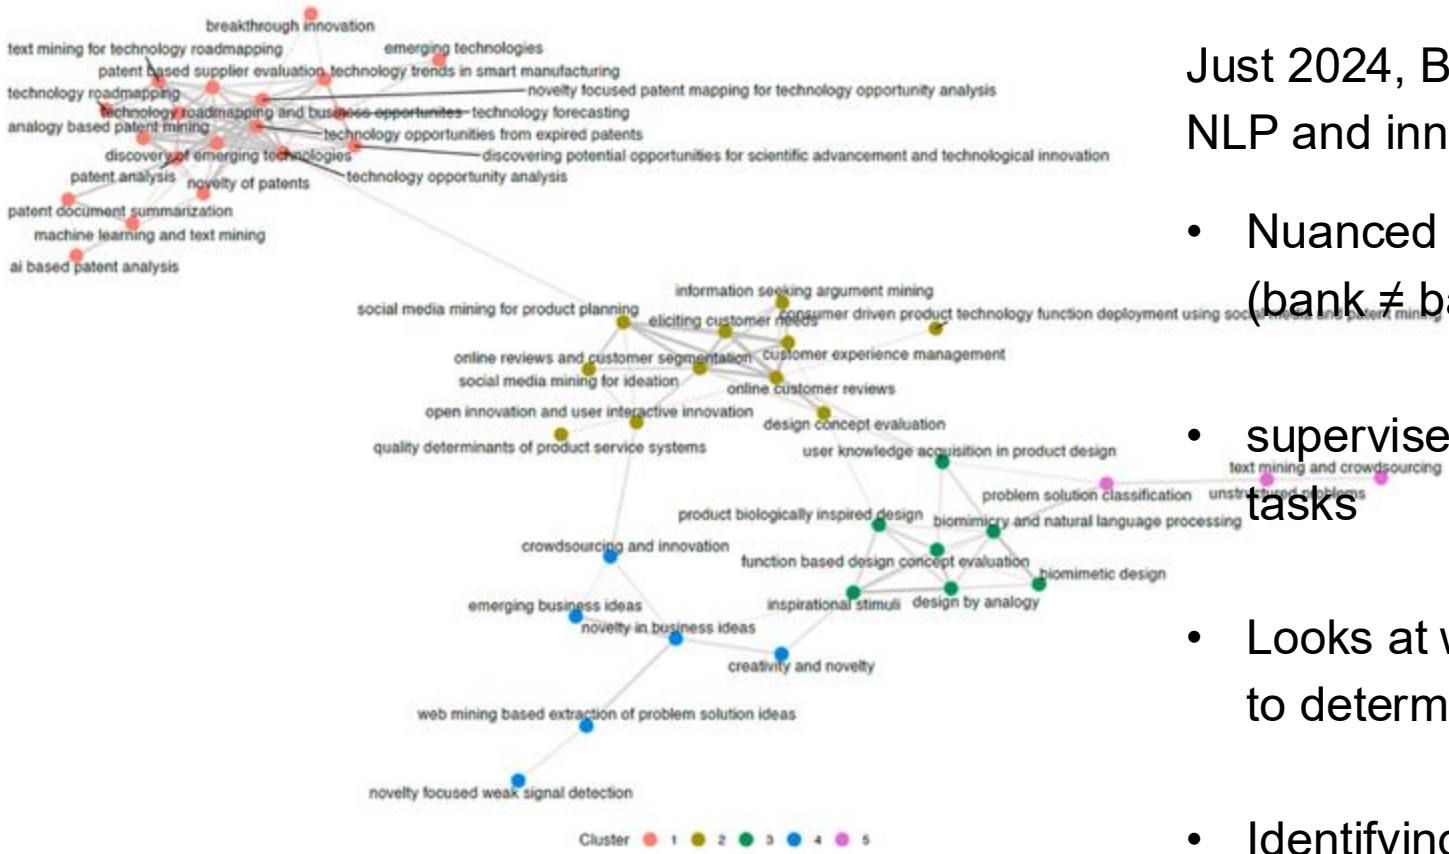

Fig. 5. Thematic topic network of contents in the analyzed articles.

Just 2024, BERTopic, articles on NLP and innovation

- Nuanced understanding of language (bank ≠ bank)
- supervised model, fine tuned on specific tasks
- Looks at words before AND after the target to determine specific context
- Identifying rhetorical styles and subtle shifts in meaning.

GENERATIVE AI (LLMS)

- Shift from pattern recognition to text generation

- Models do not just classify, but mimic understanding by predicting the next word

- Summaries, translations, production of texts...
- For agent-based models and surveys: creation of synthetic data

- BUT: hallucinations, proprietary models prevent peer verification, embedded biases from training data

- Computational tools are complements to and not substitutes for human expertise.

→ Consider them as assistants. “We are now augmented social scientists.”

UNIVERSITÄT
LUZERN

Machine Learning in Innovation Research: From Big Data to Big Insights

THE COMPUTATIONAL TOOLKIT

Topic Modeling (Identifying Themes)

An unsupervised method that detects latent patterns and groupe frequently co-occurring words into themes.

Word Embeddings (Mapping Meaning)

Creates numeric vector representations to map "semantic space" and measure similarity between concepts.

Generative LLMs (Contextual Analysis)

Uses models like BERT or GPT to understand language in context and automate coding.

Thank you
sophie.muetzel@unilu.ch

METHOD CAPABILITIES IN INNOVATION RESEARCH

Method	Primary Strength	Innovation Research Use Case
Topic Modeling	Pattern Recognition	Identifying the emergence of new technological fields.
Word Embeddings	Relational Mapping	Measuring the novelty and "semantic distance" of ideas.
LLMe (GPT/BERT)	Contextual Coding	Act-as-researcher for large-scale text annotation and coding.

BALANCING TECHNOLOGY & HUMAN EXPERTISE

The Data Quality Gap

Unstructured data requires extensive curation to remove errors, superfluous info, and algorithmic blases.

Interpretive Uncertainty

Computational outputs are "block boxes" that require human context to become semamically meaningful.

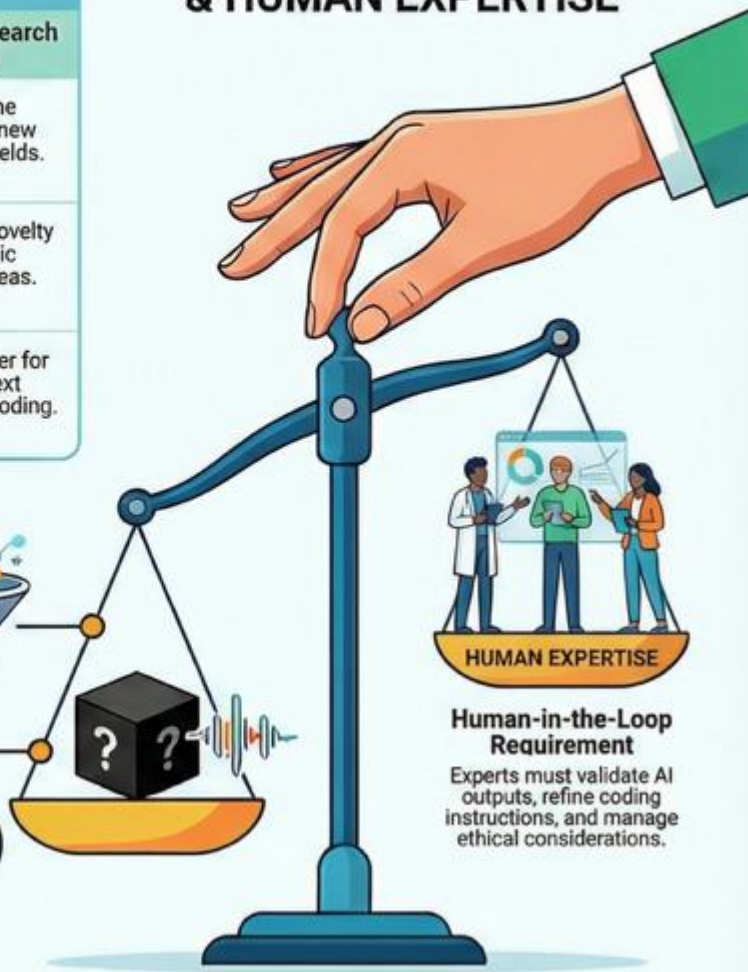

Human-in-the-Loop Requirement

Experts must validate AI outputs, refine coding instructions, and manage ethical considerations.